Identyfikacja Procesów – Projekt 1

Usuwanie zakłóceń impulsowych z nagrań muzycznych

Grupa II: Karolina Grodź 188664, Kajetan Powała-Mosiński 193054

1 Cel projektu

Celem projektu jest napisanie programu w języku MATLAB lub Python, który usuwa sztucznie dodane zakłócenia impulsowe (tzw. trzaski, kliki) z około 20-sekundowego nagrania muzycznego. Grupie II przydzielono nagranie zapisane w pliku `02.wav`. Zgodnie z treścią zadania eliminacja zakłóceń przebiega następująco:

1. Przyjmuje się model autoregresyjny rzędu $r = 4$ do lokalnej reprezentacji dynamiki sygnału.
2. Zmiany parametrów a_i $(i = 1, \ldots, r)$ modelu AR(r) śledzi się na bieżąco algorytmem ważonych najmniejszych kwadratów (EW-LS). W każdym kroku algorytmu detektor zakłóceń impulsowych kwestionuje te próbki, dla których moduł błędu predykcji przekracza trzykrotność lokalnej wartości odchylenia standardowego błędu resztowego.
3. Próbki zakwestionowane przez detektor rekonstruuje się metodą interpolacji liniowej: zakwestionowaną próbkę zastępuje się średnią arytmetyczną sąsiednich, poprawnych próbek sygnału.

Przyjmuje się przy tym, że zakłócenia mogą występować w seriach obejmujących maksymalnie 4 próbki.

2 Dane

Plik `02.wav` zawiera jednokanałowy sygnał o częstotliwości próbkowania $f_s = 22\,050$ Hz, zapisany 16-bitowymi słowami: 468 587 próbek, czyli 21,3 s. Na potrzeby obliczeń próbki przeskalowano do przedziału $[-1, 1)$ (podzielono przez 2^{15}).

Sygnał muzyczny nie przekracza amplitudy około 0,24. Zakłócenia mają postać pojedynczych lub kilkupróbkowych szpilek o amplitudzie dochodzącej do pełnej skali (rys. 1, górny wykres). W nagraniu jest 123 próbki o module większym niż 0,3. Można zatem bezpiecznie założyć, że należą one do zakłóceń.

3 Opis metody

Metodę oparto na treści zadania oraz na prezentacji *Elimination of clicks* prof. Macieja Niedźwieckiego, będącej częścią wykładu z przedmiotu Identyfikacja Procesów [1]. W dalszej części sprawozdania określenie *wykład* odnosi się do tej prezentacji.

3.1 Model sygnału

Lokalnie sygnał opisano modelem AR(r), $r = 4$:

$$y(k) = \sum_{i=1}^{r} a_i(k)\, y(k-i) + e(k) = \boldsymbol{\varphi}^T(k)\, \boldsymbol{\theta}(k) + e(k), \tag{1}$$

gdzie $\boldsymbol{\theta}(k) = [a_1(k), \ldots, a_r(k)]^T$ jest wektorem (wolnozmiennych) parametrów, $\boldsymbol{\varphi}(k) = [x(k-1), \ldots, x(k-r)]^T$ wektorem regresji, a $e(k)$ szumem resztowym. Wektor regresji budowany jest z sygnału już oczyszczonego $x(\cdot)$: próbki wcześniej uznane za zakłócone są w nim zastąpione wartościami zrekonstruowanymi (sekcja 3.5).

3.2 Algorytm EW-LS

Parametry modelu wyznaczano rekurencyjnie, minimalizując ważone wykładniczo kryterium $\sum_{j \le k} \lambda^{k-j} \big(y(j) - \boldsymbol{\varphi}^T(j)\boldsymbol{\theta}\big)^2$, gdzie $0 < \lambda < 1$ jest współczynnikiem zapominania. Algorytm w każdym kroku wyznacza:

$$\varepsilon(k) = y(k) - \boldsymbol{\varphi}^T(k)\,\hat{\boldsymbol{\theta}}(k-1), \tag{2}$$

$$\mathbf{k}(k) = \frac{\mathbf{P}(k-1)\,\boldsymbol{\varphi}(k)}{\lambda + \boldsymbol{\varphi}^T(k)\,\mathbf{P}(k-1)\,\boldsymbol{\varphi}(k)}, \tag{3}$$

$$\hat{\boldsymbol{\theta}}(k) = \hat{\boldsymbol{\theta}}(k-1) + \mathbf{k}(k)\,\varepsilon(k), \tag{4}$$

$$\mathbf{P}(k) = \frac{1}{\lambda}\left[\mathbf{P}(k-1) - \frac{\mathbf{P}(k-1)\boldsymbol{\varphi}(k)\boldsymbol{\varphi}^T(k)\mathbf{P}(k-1)}{\lambda + \boldsymbol{\varphi}^T(k)\,\mathbf{P}(k-1)\,\boldsymbol{\varphi}(k)}\right], \tag{5}$$

z warunkami początkowymi $\hat{\boldsymbol{\theta}}(0) = \mathbf{0}$, $\mathbf{P}(0) = \delta\mathbf{I}$, $\delta = 100$. Efektywna pamięć estymatora wynosi około $1/(1-\lambda)$ próbek. Na próbkach zakwestionowanych przez detektor model nie jest aktualizowany.

Zabezpieczenia numeryczne. Sygnał audio próbkowany z częstotliwością 22 kHz jest silnie skorelowany, a macierz kowariancji wektora regresji jest źle uwarunkowana. W takich warunkach błędy zaokrągleń szybko odbierają macierzy $\mathbf{P}$ symetrię i dodatnią określoność, co prowadzi do rozbieżności estymat. Dlatego:

- macierz $\mathbf{P}$ aktualizowana jest w postaci symetrycznej podanej wyżej, a po każdym kroku dodatkowo symetryzowana: $\mathbf{P} \leftarrow \frac{1}{2}(\mathbf{P} + \mathbf{P}^T)$,
- ślad macierzy jest ograniczony: jeśli $\operatorname{tr}\mathbf{P}(k) > 10^4$, to macierz jest przeskalowywana do śladu równego 10^4. Zapobiega to niekontrolowanemu wzrostowi $\mathbf{P}$ w słabo pobudzanych kierunkach przestrzeni parametrów (*estimator windup*).

3.3 Detektor zakłóceń

Zgodnie z wykładem [1] lokalną wariancję błędu predykcji jednokrokowej $\varepsilon(k) = y(k) - \hat{y}(k \mid k-1)$ estymowano jako średnią z okna przesuwnego obejmującego M poprzednich błędów:

$$\hat{\sigma}_\varepsilon^2(k) = \frac{1}{M}\sum_{i=1}^{M} \varepsilon^2(k-i), \qquad M = 20. \tag{6}$$

Do okna trafiają wyłącznie błędy próbek uznanych za poprawne. Gdyby uwzględniać błędy próbek zakłóconych (rzędu 1), estymata $\hat{\sigma}_\varepsilon$ byłaby zawyżona przez kolejne M próbek i maskowałaby zakłócenia występujące tuż po sobie.

Wynik detektora $\hat{d}(k)$ wyznaczany jest według reguły decyzyjnej z wykładu:

$$\hat{d}(k) = \begin{cases} 0 & \text{gdy } |\varepsilon(k)| \le \mu\,\hat{\sigma}_\varepsilon(k), \\ 1 & \text{gdy } |\varepsilon(k)| > \mu\,\hat{\sigma}_\varepsilon(k), \end{cases} \qquad \mu = 3, \tag{7}$$

gdzie $\hat{d}(k) = 1$ oznacza próbkę zakwestionowaną. Wielkość $\mu\,\hat{\sigma}_\varepsilon(k)$ to próg kwalifikujący próbkę jako błędną; jego przebieg pokazano na rys. 4. Według wykładu w zastosowaniach audio próg μ dobiera się empirycznie, zwykle z przedziału $[3, 5]$. Treść zadania narzuca wartość $\mu = 3$. Detekcja jest włączana po 500 próbkach, gdy estymaty $\hat{\boldsymbol{\theta}}$ zdążą się ustalić.

3.4 Wyznaczanie długości serii zakłóceń

Zakwestionowanie próbki $y(k)$ rozpoczyna potencjalną serię zakłóceń o długości $m \in \{1, \ldots, 4\}$. Długość serii wyznaczana jest przez sprawdzenie kolejnych próbek $y(k+1), \ldots, y(k+4)$ względem predykcji wielokrokowej obliczonej z ostatnich poprawnych próbek $x(k-1), \ldots, x(k-r)$. Predykcję $\hat{y}(k+j \,|\, k-1)$ uzyskuje się, stosując rekurencyjnie model AR z parametrami $\hat{\boldsymbol{\theta}}(k-1)$, przy czym w miejsce nieznanych próbek $y(k), \ldots, y(k+j-1)$ podstawia się ich predykcje.

Wariancja błędu predykcji h-krokowej jest większa niż jednokrokowej:

$$\sigma_h^2 = \hat{\sigma}_\varepsilon^2 \sum_{i=0}^{h-1} \psi_i^2, \qquad \psi_0 = 1, \quad \psi_i = \sum_{j=1}^{\min(i,r)} \hat{a}_j \, \psi_{i-j}, \tag{8}$$

gdzie ψ_i jest odpowiedzią impulsową filtru $1/A(z^{-1})$ modelu AR. Długością serii jest najmniejsze m, dla którego próbka $y(k+m)$ jest zgodna z predykcją:

$$|y(k+m) - \hat{y}(k+m \,|\, k-1)| \le \mu \, \sigma_{m+1}. \tag{9}$$

Jeśli żadna z próbek $y(k+1), \ldots, y(k+4)$ nie spełnia tego warunku, odchylenie nie jest traktowane jako zakłócenie impulsowe, lecz jako rzeczywista zmiana charakteru sygnału (np. atak dźwięku). Próbka $y(k)$ zostaje wtedy przyjęta jako poprawna i użyta do aktualizacji modelu.

Skalowanie progu przez σ_{m+1} jest niezbędne. W cichych fragmentach nagrania błąd predykcji wielokrokowej dla poprawnych próbek następujących po trzasku przekracza próg jednokrokowy $3\hat{\sigma}_\varepsilon$. Bez skalowania seria wydłużałaby się ponad 4 próbki, a trzask byłby błędnie przepuszczany.

3.5 Rekonstrukcja próbek

Zakwestionowane próbki zastępowano interpolacją liniową między ostatnią poprawną próbką $x(k-1)$ a pierwszą poprawną próbką po serii $y(k+m)$:

$$x(k+i-1) = x(k-1) + \frac{i}{m+1} \, [y(k+m) - x(k-1)], \qquad i = 1, \ldots, m. \tag{10}$$

Dla pojedynczej próbki ($m = 1$) wzór sprowadza się do $x(k) = \frac{1}{2} \, [x(k-1) + y(k+1)]$, zgodnie z treścią zadania.

Zrekonstruowane wartości od razu zapisywane są do sygnału x, z którego budowany jest wektor regresji. Są one zawsze ograniczone przez rzeczywiste próbki sąsiednie, więc model AR nie uczy się na wartościach wygenerowanych przez siebie samego, co mogłoby prowadzić do sprzężenia zwrotnego i rozbieżności estymat.

Wykład [1] podaje również rekonstrukcję optymalną w sensie średniokwadratowym. Brakujące próbki wyznacza się, minimalizując sumę kwadratów błędów predykcji modelu AR(r) na przedziale obejmującym serię i r następnych próbek:

$$J = \sum_{t=k}^{k+m+r-1} \Big[x(t) - \sum_{i=1}^{r} a_i \, x(t-i) \Big]^2 \;\longrightarrow\; \min_{x(k), \ldots, x(k+m-1)}. \tag{11}$$

Dla modelu AR(1) i jednej brakującej próbki daje to $\hat{x}(k) = a \, [x(k-1) + x(k+1)]/(1 + a^2)$. Interpolacja liniowa jest szczególnym, uproszczonym przypadkiem tego wzoru (dla $a = 1$). Zgodnie z treścią zadania zastosowano interpolację liniową.

4 Opis programu

Program napisano w języku Python z użyciem bibliotek `numpy` i `matplotlib`; plik WAV odczytywany i zapisywany jest standardowym modułem `wave`. Program domyślnie przetwarza plik `02.wav`, zapisuje sygnał wynikowy do pliku `02_odszumiony.wav`, a wykresy do katalogu `wykresy/`. Składa się z następujących funkcji:

- `read_wav`, `write_wav` – odczyt i zapis sygnału 16-bitowego,
- `remove_clicks` – główna pętla: algorytm EW-LS, estymacja wariancji (okno przesuwne M ostatnich kwadratów błędów, `collections.deque`), detekcja i rekonstrukcja (sekcje 3.2–3.5),
- `burst_length` – wyznaczanie długości serii zakłóceń na podstawie predykcji wielokrokowej (sekcja 3.4),
- `multistep_gain` – współczynnik $\sum_{i=0}^{h-1} \psi_i^2$,
- `plot_results` – wykresy zamieszczone w sprawozdaniu.

Po zakończeniu program wypisuje liczbę zakwestionowanych próbek i rozkład długości wykrytych serii.

5 Dobór nastaw

Przyjęte wartości nastaw zestawiono w tabeli 1.

Tabela 1: Nastawy algorytmu

Symbol	Wartość	Pamięć efektywna	Znaczenie
r	4	—	rząd modelu AR (wg treści zadania)
λ	0,999	1000 próbek (≈45 ms)	zapominanie w EW-LS
M	20	20 próbek (≈0,9 ms)	okno estymatora $\hat{\sigma}_\varepsilon^2$ (wg wykładu)
μ	3	—	krotność $\hat{\sigma}_\varepsilon$ w progu (wg treści zadania)
$m_{\max}$	4	—	maks. długość serii (wg treści zadania)
δ	100	—	$\mathbf{P}(0) = \delta\mathbf{I}$
$\operatorname{tr}\mathbf{P}_{\max}$	10^4	—	ograniczenie śladu $\mathbf{P}$

Wpływ współczynnika zapominania, długości okna i progu zbadano, uruchamiając program dla kilku wariantów nastaw (tabela 2). Jako miarę skuteczności przyjęto liczbę próbek o module większym niż 0,3 pozostałych po odszumieniu. Takie próbki na pewno są zakłóceniami, bo sygnał muzyczny nie przekracza amplitudy 0,24. Liczba wykrytych serii mówi natomiast, ile fragmentów sygnału zostało zmodyfikowanych. Jej nadwyżka ponad rzeczywistą liczbę trzasków to fałszywe alarmy.

Tabela 2: Porównanie wariantów nastaw (pozostałe nastawy jak w tabeli 1)

Wariant	Zakwest. próbki	Wykryte serie	Próbki $> 0{,}3$ po odszumieniu	$\max \lvert\hat{a}_i\rvert$
nastawy przyjęte	**8181**	**4674**	**0**	**2,49**
$\lambda = 0{,}99$	8284	4744	0	2,93
$\lambda = 0{,}995$	8115	4677	0	2,74
$\lambda = 0{,}9995$	7949	4518	0	2,45
$M = 10$	13757	7584	4	2,49
$M = 50$	5399	3184	0	2,50
$M = 100$	4121	2463	0	2,50
$\mu = 4$	844	571	1	2,50
$\mu = 5$	250	204	0	2,50
sygnał przed odszumieniem	—	—	123	—

Współczynnik zapominania λ. Muzykę można uznać za lokalnie stacjonarną w przedziałach rzędu kilkudziesięciu milisekund. Wartość $\lambda = 0{,}999$ odpowiada oknu efektywnemu około 45 ms, co jest kompromisem między szybkością śledzenia zmian parametrów a ich wariancją. Mniejsze wartości (0,99, 0,995) dają bardziej zaszumione estymaty (większy rozrzut $\hat{a}_i$) i nieco więcej fałszywych alarmów. Wartość 0,9995 daje niewiele mniej detekcji, ale okno 90 ms gorzej nadąża za szybkimi zmianami brzmienia. Różnice są niewielkie: algorytm nie jest szczególnie wrażliwy na λ w tym zakresie.

Długość okna M. Przyjęto wartość $M = 20$ zaproponowaną w wykładzie [1]. Krótkie okno pozwala progowi szybko nadążać za zmianami głośności muzyki. Konsekwencją jest duża wariancja samej estymaty: średnia z 20 kwadratów błędów ma względne odchylenie standardowe około $\sqrt{2/M} \approx 32\%$. Chwilowe zaniżenia $\hat{\sigma}_\varepsilon$ powodują fałszywe alarmy. Dłuższe okno ($M = 50$, 100) daje gładszy próg i 1,5–2 razy mniej wykrytych serii przy nadal pełnej skuteczności usuwania dużych zakłóceń. Okno zbyt krótkie ($M = 10$) jest szkodliwe: estymata jest tak zaszumiona, że detektor kwestionuje zbyt wiele kolejnych próbek. Seria przekracza wtedy 4 próbki i trzask zostaje przepuszczony (4 próbki o module powyżej 0,3 pozostały w sygnale). Wartość $M = 20$ jest najkrótszym z badanych okien, przy którym wszystkie duże zakłócenia są usuwane.

Próg μ. Treść zadania narzuca $\mu = 3$, czyli dolną granicę przedziału $[3, 5]$ zalecanego w wykładzie. Gdyby błąd predykcji miał rozkład normalny, a jego wariancja była znana, prawdopodobieństwo przekroczenia progu 3σ wynosiłoby 0,27%, czyli około 1260 fałszywych alarmów na 468 587 próbek. Rzeczywista liczba jest większa (4674 wykryte serie przy około 120–200 rzeczywistych trzaskach) z dwóch powodów: sygnał muzyczny ma rozkład o cięższych ogonach, a wariancja jest estymowana z zaledwie 20 próbek. Fałszywe alarmy są w praktyce nieszkodliwe: dotyczą głównie pojedynczych próbek, a interpolacja liniowa jednej próbki muzyki próbkowanej z częstotliwością 22 kHz wprowadza znikome zniekształcenia.

Zwiększenie progu radykalnie zmniejsza liczbę modyfikacji: przy $\mu = 4$ wykrytych serii jest 8 razy mniej, przy $\mu = 5$ ponad 20 razy mniej. Przy $\mu = 4$ jedna próbka zakłócenia (o module 0,39) pozostała jednak w sygnale, a przy $\mu = 5$ wszystkie duże zakłócenia zostały usunięte. Wynik nie jest więc monotoniczny względem μ, co potwierdza uwagę z wykładu, że próg trzeba dobierać empirycznie. Zgodnie z treścią zadania zachowano wartość $\mu = 3$.

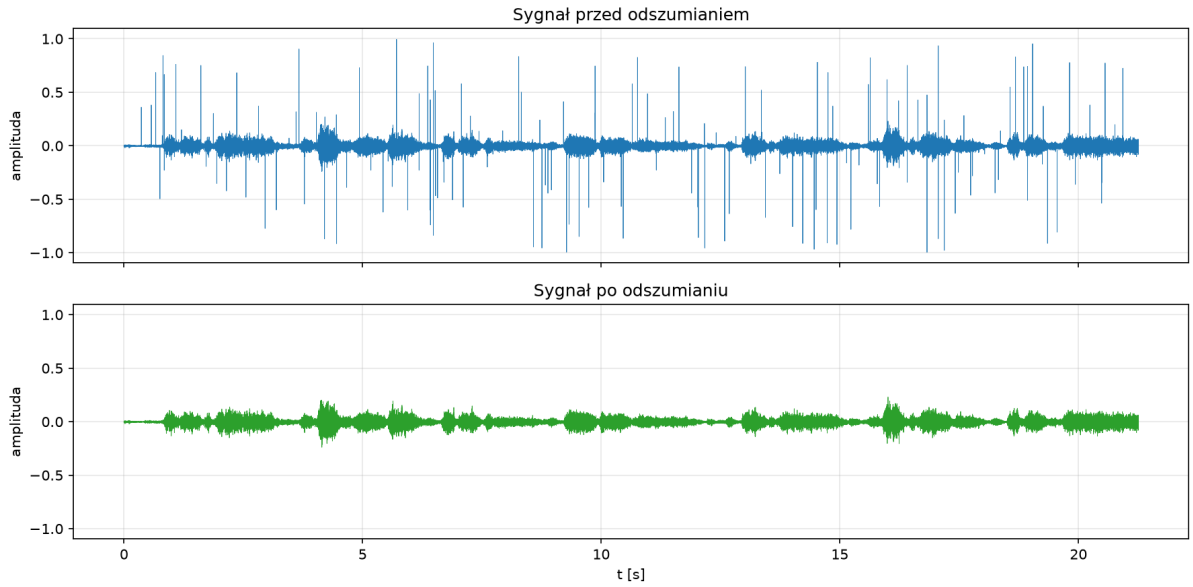
6 Wyniki

Program zakwestionował 8181 próbek w 4674 seriach. Rozkład długości serii przedstawia tabela 3.

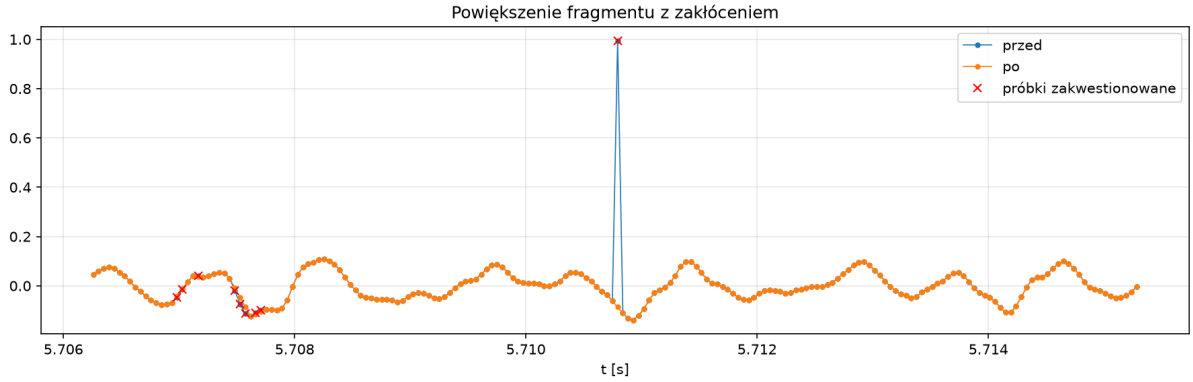
Tabela 3: Rozkład długości wykrytych serii zakłóceń

Długość serii m	1	2	3	4
Liczba serii	2421	1365	524	362

Na rys. 1 porównano sygnał przed odszumianiem i po nim. Wszystkie widoczne szpilki zostały usunięte, a maksymalna amplituda sygnału spadła z 0,996 do 0,240, czyli do poziomu samej muzyki. Rys. 2 przedstawia powiększenie fragmentu z zakłóceniem o największej amplitudzie (trzask o wartości 0,995 w chwili $t \approx 5{,}711$ s), zastąpionym wartością zinterpolowaną. Na tym samym wykresie widać też przykłady fałszywych alarmów w przedziale $t \approx 5{,}707$–$5{,}708$ s: kilka próbek na zboczach sygnału zinterpolowano, ale zmiana przebiegu jest niezauważalna.

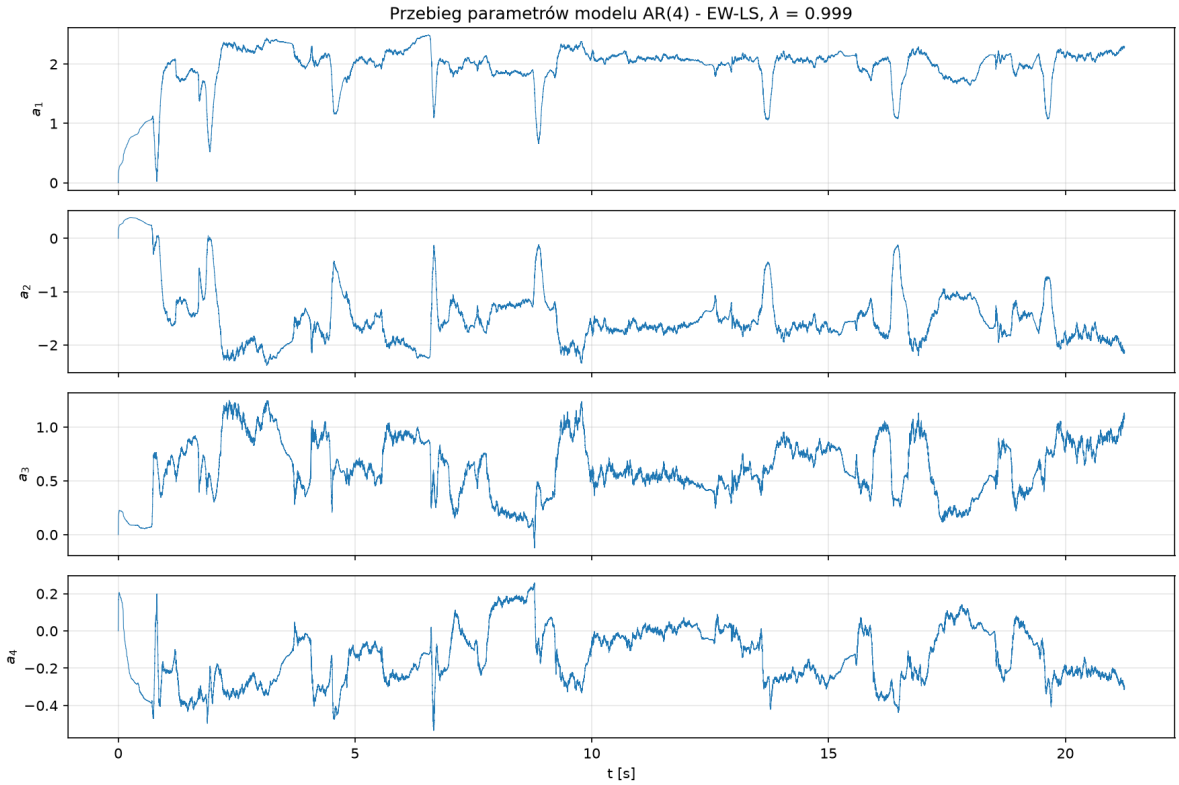


Rysunek 1: Sygnał przed odszumianiem (u góry) i po odszumianiu (u dołu)



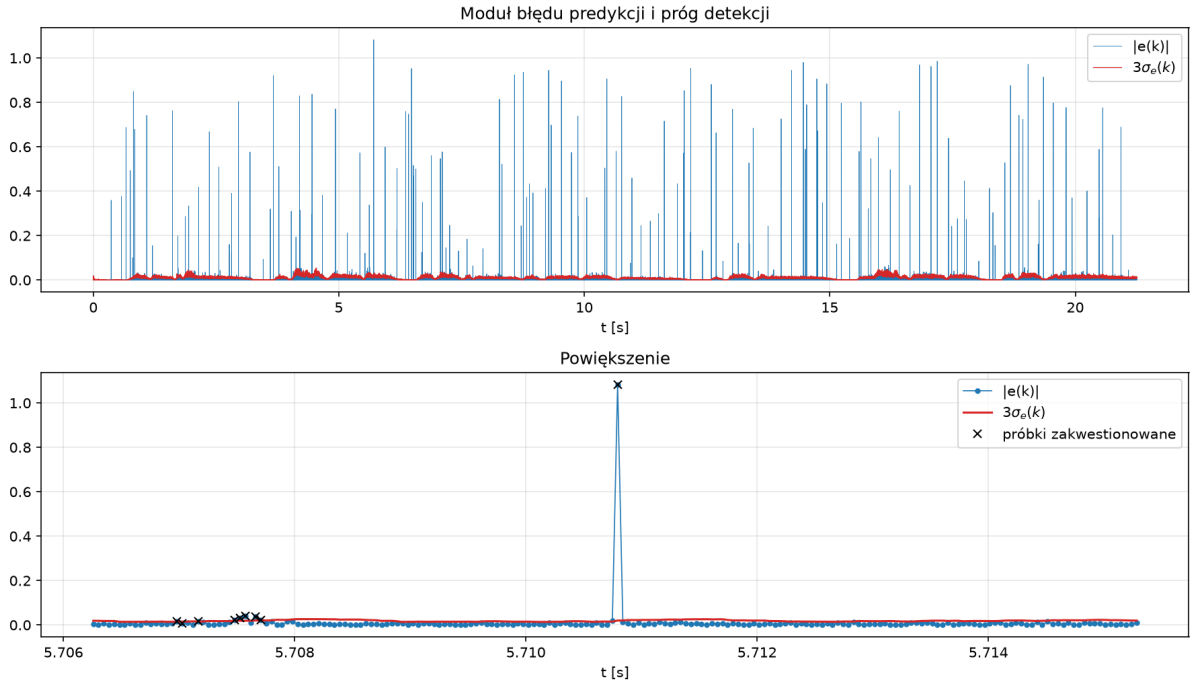
Rysunek 2: Powiększenie fragmentu z zakłóceniem o największej amplitudzie; krzyżykami oznaczono próbki zakwestionowane przez detektor

Przebiegi estymat parametrów modelu AR(4) pokazano na rys. 3. Po krótkim okresie zbieżności (około 1 s, w którym nagranie jest prawie ciche) parametry zmieniają się w ograniczonym zakresie: $\hat{a}_1 \in [0{,}5;\ 2{,}5]$, $\hat{a}_2 \in [-2{,}4;\ 0]$, $\hat{a}_3 \in [-0{,}1;\ 1{,}3]$, $\hat{a}_4 \in [-0{,}55;\ 0{,}25]$. Wyraźne skoki parametrów (np. przy $t \approx 2$; 4,5; 6,6; 8,8; 13,6; 16,4; 19,6 s) pokrywają się ze zmianami brzmienia nagrania: model śledzi zmiany lokalnej charakterystyki widmowej sygnału. Trzaski nie zaburzają estymat, ponieważ próbki zakwestionowane nie są używane do aktualizacji modelu.



Rysunek 3: Przebieg estymat parametrów $\hat{a}_1, \ldots, \hat{a}_4$ modelu AR(4)

Rys. 4 przedstawia moduł błędu predykcji $|\varepsilon(k)|$ na tle progu detekcji $3\hat{\sigma}_\varepsilon(k)$. Na górnym wykresie błędy odpowiadające trzaskom (do około 1) są o dwa rzędy wielkości większe niż próg (mediana około 0,01). Próg zmienia się wraz z głośnością nagrania: we fragmentach cichych spada do około 0,001, w głośnych rośnie do 0,03–0,05. Dolny wykres (powiększenie) pokazuje zachowanie detektora w pobliżu największego trzasku.



Rysunek 4: Moduł błędu predykcji i próg kwalifikujący próbkę jako błędną $3\hat{\sigma}_\varepsilon(k)$: cały sygnał (u góry) i powiększenie (u dołu)

Ocena odsłuchowa

Porównano odsłuchowo plik wejściowy `02.wav` z plikiem wynikowym `02_odszumiony.wav`. Dźwięk po odszumieniu jest bardzo czysty: nie słychać trzasków ani szumów. Mimo dużej liczby fałszywych alarmów detektora nie słychać też zniekształceń muzyki wynikających z interpolacji poprawnych próbek. Potwierdza to, że zinterpolowanie pojedynczych próbek sygnału próbkowanego z częstotliwością 22 kHz jest niesłyszalne.

7 Wnioski

- Adaptacyjny model AR(4) identyfikowany algorytmem EW-LS wraz z detektorem 3σ i interpolacją liniową usunął wszystkie duże zakłócenia impulsowe z nagrania. Po odszumieniu nie pozostała żadna próbka o amplitudzie przekraczającej poziom sygnału muzycznego, a odsłuch potwierdza brak słyszalnych trzasków.
- Dla silnie skorelowanego sygnału audio algorytm EW-LS wymaga zabezpieczeń numerycznych: symetrycznej postaci aktualizacji macierzy $\mathbf{P}$ i ograniczenia jej śladu.
- Wektor regresji budowany z sygnału oczyszczonego (z próbkami zrekonstruowanymi przez interpolację) zapewnia stabilne śledzenie parametrów również w otoczeniu zakłóceń.
- Przy wyznaczaniu długości serii zakłóceń próg należy skalować wariancją błędu predykcji wielokrokowej; w przeciwnym razie w cichych fragmentach trzaski nie są wykrywane.
- Próg 3σ w połączeniu z krótkim oknem estymatora wariancji ($M = 20$, wg wykładu) daje dużą liczbę fałszywych alarmów (około 4700 serii przy 120–200 rzeczywistych trzaskach), które jednak nie wpływają słyszalnie na jakość nagrania. Liczbę fałszywych alarmów można zmniejszyć, wydłużając okno ($M = 50$–100) lub zwiększając próg w zalecanym przedziale $\mu \in [3, 5]$.

- Zgodnie z treścią zadania zastosowano interpolację liniową. Lepszą jakość rekonstrukcji, zwłaszcza dłuższych serii, mogłaby dać przedstawiona w wykładzie rekonstrukcja optymalna w sensie średniokwadratowym, oparta na modelu AR.

Literatura

[1] M. Niedźwiecki, *Elimination of clicks*, prezentacja do wykładu z przedmiotu Identyfikacja Procesów.